

# Cross-Modal Interaction Networks for Query-Based Moment Retrieval in Videos

---

Zhu Zhang, Zhijie Lin, Zhou Zhao, Zhenxin Xiao  
SIGIR 2019

# Task

---

## Query-Based Moment Retrieval

- 動画の一部を説明した文章を受けて、それに対応する場면을動画内からローカライズするタスク

**Language Query:**  
A person runs to the window and then look out



[TALL](#)

# Related works

---

- [MCN\(Moment Context networks\)](#) (Hendricks, ICCV2017)  
動画特徴量(動画全体のglobal featureとタイムスタンプ内のlocal featureの合成)と言語特徴量の分布が最短距離となるタイムスタンプを推定
- [CTRL\(Cross-modal Temporal Regression Localizer\)](#) (Gao, ICCV2017)  
クリップ動画(複数の固定サイズ)と言語の特徴量をcross-modalに合成  
アライメントスコアを推定し, 最大スコアのモーメントの回帰を行って  
ローカライズ
- [ACRN\(Attentive Cross-modal Retrieval Network\)](#) (Liu, SIGIR2018)  
attentionを組み込んで認識により有効な特徴量を強調  
各モーダル特徴量と融合特徴量を合成  
回帰モデルからアライメントスコアとオフセットを算出し, ローカライズ
- [QSPN\(Query-Guided Proposal Network\)](#) (Xu, AAAI2019)  
動画特徴量と言語特徴量をattentionを組み込んでearly fusionするマルチモデルからclassificationとregressionで学習  
クエリの再生成を補助タスク

# Problem

## query representation → RNN

- query文の**文法的な文構造**を捉え切れていない

## video representation → CNN+RNN

- 動画のsemanticな関係性の情報を**長期的**に捉えることができない

## Cross-modal Interaction → attention (fusion)

- 一般的なattentionが**一層だけ**設けられているのみで十分な相互関係を見ることができない




Figure 1: Query-Based Moment Retrieval in Video

# Approach

## query representation

→ GCN層によってquery文の文法的な構造を捉える

## video representation

→ multi-head self-attention層によって動画の長期的でsemanticな関係性を捉える

## Cross-modal Interaction → attention (fusion)

→ cross-modal interaction層の多層化によって効率的にモーダル間の統合的な情報を捉える





Figure 1: Query-Based Moment Retrieval in Video

# Proposed Method



## 4モジュール構成


- a. syntactic GCNモジュール
- b. Multi-Head Self-Attentionモジュール
- c. Multi-Stage Cross-Modal Interactionモジュール
- d. Moment Retrievalモジュール

# Proposed Method (Query)

## 文法的な文構造


入力: query

出力: syntactic-aware query representation



a) Syntactic GCN Module

- 文法的な構造関係の有向グラフを作成



$$\mathbf{g}_i^1 = \text{ReLU} \left( \sum_{j \in \mathcal{N}(i)} \mathbf{w}_{dir(i,j)}^g \mathbf{h}_j^q + \mathbf{b}_{lab(i,j)}^g \right)$$

- syntactic GCNを介して文法的な文構造を考慮した特徴量

$$\mathbf{o}_i^1 = \mathbf{g}_i^1 + \mathbf{h}_i^q$$

$$\begin{cases} \mathbf{g}^1 = \text{synGCN}(\mathbf{h}^q), \mathbf{o}^1 = \mathbf{g}^1 + \mathbf{h}^q \\ \mathbf{g}^l = \text{synGCN}(\mathbf{o}^{l-1}), \mathbf{o}^l = \mathbf{g}^l + \mathbf{o}^{l-1} \end{cases}$$


$$\mathbf{o}^l = (\mathbf{o}_1^l, \mathbf{o}_2^l, \dots, \mathbf{o}_m^l)$$

# Proposed Method (Video)

## 動画の長期的でsemanticな関係性

入力: video

出力: video semantic representation



b) Multi-Head Self-Attention Module

- Multi-Head Self-Attentionによって近接フレーム間だけでなく、離れたフレーム間の関係性も考慮

$$\text{Attention}(\bar{Q}, \bar{K}, \bar{V}) = \text{Softmax}\left(\frac{\bar{Q}^T \bar{K}}{\sqrt{d_k}}\right) \bar{V}^T$$

$$\text{MultiHead}(\bar{Q}, \bar{K}, \bar{V}) = \mathbf{W}^O \text{Concat}(\text{head}_1, \dots, \text{head}_H)$$

$$\text{where head}_i = \text{Attention}(\mathbf{W}_i^Q \bar{Q}, \mathbf{W}_i^K \bar{K}, \mathbf{W}_i^V \bar{V})$$

$$\mathbf{V}^S = \text{MultiHead}(\mathbf{V}, \mathbf{V}, \mathbf{V}) + \mathbf{V}$$

# Proposed Method (Cross-Modal)

入力: query and video semantic representation

出力: cross-modal representation

- Attentive Aggregation

attentionベースで各単語 $j$ と各フレーム $i$ との関係性 $M_{ij}^{row}$   
フレーム毎でのqueryの集約表現 $\mathbf{h}_i^s$

$$\mathbf{h}_i^s = \sum_{j=1}^m M_{ij}^{row} \mathbf{o}_j^l$$

- Cross Gate


queryの集約表現 $\mathbf{h}_i^s$ とframe semantic表現 $\mathbf{h}_i^v$ との関係性から重要度が重み付け

$$\tilde{\mathbf{h}}_i^s = \mathbf{h}_i^s \odot \sigma(\mathbf{W}^v \mathbf{h}_i^v + \mathbf{b}^v)$$

$$\tilde{\mathbf{h}}_i^v = \mathbf{h}_i^v \odot \sigma(\mathbf{W}^s \mathbf{h}_i^s + \mathbf{b}^s)$$

- Bilinear Fusion

cross-modal表現 $\mathbf{f} = (\mathbf{f}_1, \dots, \mathbf{f}_n)$ を獲得



# Proposed Method (Localization)

入力: cross-modal representation

出力: moment

- 複数サイズ $k$ の固定幅ウィンドウを候補として用意
- 各タイムステップ $i$ においてウィンドウをセット
- 同時にconfidence score  $cs_i$ を算出
- これらのモーメントのオフセット(差分) $\hat{\delta}_s, \hat{\delta}_e$ を推定

Loss

- Alignment loss


算出されるアライメントスコアconfidence scoreに対して

$$L_{align} = -\frac{1}{nk} \sum_{i=1}^n \sum_{j=1}^k (1 - \text{IoU}_{ij}) \cdot \log(1 - cs_{ij}) + \text{IoU}_{ij} \cdot \log(cs_{ij})$$

- Regression loss

オフセットに対して $(\delta_s, \delta_e)$ :GT,  $(\hat{\delta}_s, \hat{\delta}_e)$ :predicted

$$L_{reg} = -\frac{1}{N} \sum \left( \text{L1}(\delta_s - \hat{\delta}_s) + \text{L1}(\delta_e - \hat{\delta}_e) \right)$$



# Results

---

**Table 2: Performance Evaluation Results on the ActivityCaption Dataset ( $n \in \{1, 5\}$  and  $m \in \{0.3, 0.5, 0.7\}$ ).**

Method	R@1	R@1	R@1	R@5	R@5	R@5
	IoU=0.3	IoU=0.5	IoU=0.7	IoU=0.3	IoU=0.5	IoU=0.7
MCN	39.35	21.36	6.43	68.12	53.23	29.70
VSA-RNN	39.28	23.43	9.01	70.84	55.52	32.12
VSA-STV	41.71	24.01	8.92	71.05	56.62	34.52
CTRL	47.43	29.01	10.34	75.32	59.17	37.54
ACRN	49.70	31.67	11.25	76.50	60.34	38.57
QSPN	52.13	33.26	13.43	77.72	62.39	40.78
<b>CMIN</b>	<b>63.61</b>	<b>43.40</b>	<b>23.88</b>	<b>80.54</b>	<b>67.95</b>	<b>50.73</b>

**Table 3: Performance Evaluation Results on the TACoS Dataset ( $n \in \{1, 5\}$  and  $m \in \{0.1, 0.3, 0.5\}$ ).**

Method	R@1	R@1	R@1	R@5	R@5	R@5
	IoU=0.1	IoU=0.3	IoU=0.5	IoU=0.1	IoU=0.3	IoU=0.5
MCN	3.11	1.64	1.25	3.11	2.03	1.25
VSA-RNN	8.84	10.77	4.78	19.05	13.90	9.10
VSA-STV	15.01	10.77	7.56	32.82	23.92	15.50
CTRL	24.32	18.32	13.30	48.73	36.69	25.42
ACRN	24.22	19.52	14.62	47.42	34.97	24.88
QSPN	25.31	20.15	15.23	53.21	36.72	25.30
<b>CMIN</b>	<b>32.48</b>	<b>24.64</b>	<b>18.05</b>	<b>62.13</b>	<b>38.46</b>	<b>27.02</b>

# Results

---


**Table 4: Performance Evaluation Results of Ablation Model on the ActivityCaption dataset.**

Method	R@1	R@1	R@1	R@5	R@5	R@5
	IoU=0.3	IoU=0.5	IoU=0.7	IoU=0.3	IoU=0.5	IoU=0.7
w/o. GCN	60.12	40.84	21.79	78.23	65.67	45.43
w/o. SA	61.22	41.56	22.36	79.43	66.91	48.12
w/o. CG	60.57	41.21	22.01	78.62	65.99	46.89
w/o. BF	61.32	41.89	22.12	79.27	66.21	47.92
full	<b>63.61</b>	<b>43.40</b>	<b>23.88</b>	<b>80.54</b>	<b>67.95</b>	<b>50.73</b>


**Table 5: Performance Evaluation Results of Ablation Model on the TACoS dataset.**

Method	R@1	R@1	R@1	R@5	R@5	R@5
	IoU=0.1	IoU=0.3	IoU=0.5	IoU=0.1	IoU=0.3	IoU=0.5
w/o. GCN	30.54	23.22	10.03	57.69	37.12	26.16
w/o. SA	30.21	23.02	16.87	55.54	36.6	25.37
w/o. CG	31.96	23.59	17.47	61.87	38.11	26.79
w/o. BF	32.01	<b>24.79</b>	17.61	61.59	38.23	26.75
full	<b>32.48</b>	24.64	<b>18.05</b>	<b>62.13</b>	<b>38.46</b>	<b>27.02</b>

# Results



**Figure 4: Effect of the Number of Stacked Syntactic GCN layers on the ActivityCaption Dataset.**




**Figure 5: Effect of the Number of Stacked Syntactic GCN layers on the TACoS Dataset.**




Syntactic GCN layerの層数による影響

# Results

Query : The boy drops the cloths and takes the iron away **before** the baby can pick it up.



Query : The female athlete jumped over the pole **and** wave at everyone.



**Figure 6: Examples on the ActivityCaption dataset.**

# Results

Query : **After** getting out the juicer, he juices the **first** orange half.



Ground Truth : 74.56s | ← ----- → | 120.34s

QSPN : 79.1s | ← ----- → | 129.31s

CMIN : 72.32s | ← ----- → | 117.78s

Query : She washes herb stems in the sink **before** placing them on the cuttingboard.



Ground Truth : 126.29s | ← ----- → | 127.62s


QSPN : 120.1s | ← ----- → | 133.34s

CMIN : 123.04s | ← ----- → | 130.72s

**Figure 7: Examples on the TACoS dataset.**

# Results

---



**Figure 8: The Video-to-Query Attention Results in the Multi-Stage Cross-Modal Interaction Module**